与 Boţ 讨论讲稿 · 随机 Nesterov

2026-09-29

总体思路

整场讨论只讲一句话：**随机 Nesterov 能不能加速，取决于噪声模型。持续噪声下不能；衰减噪声 JOTA 已经基本做完；相对噪声下的 a.s. 渐近分析还是空白。** 前四节都是为这句话铺垫，每一节结尾都回到它。

本讲稿依据的是 `main_20260926_ProfBot.tex`（发给 Boţ 的终版）。

时间分配（假设会议约 1–2 小时，你讲 40 分钟左右，其余时间讨论）：

部分	时长	目的
开场	2 分钟	说明材料是什么、想讨论什么
第 1 节 SGD 基准	6 分钟	立起偏差–方差结构和下界
第 2 节 随机 Nesterov	10 分钟	说明同结构、同极限，这是核心论证
第 3 节 相关工作	10 分钟	按噪声模型分三类，指出空白
第 4 节 JOTA 与开放问题	12 分钟	定位 JOTA，引出具体问题
讨论	20–80 分钟	听他的判断，带回四个答案

只有 1 小时时，第 1 节跳过步长表和 a.s. 注记，压到 4 分钟。接近 2 小时时，第 2 节可以在白板上推一遍单步不等式和 $\delta = 3/2$ 的平衡，第 4 节可以展开问题 1 的初步思路。

语气原则：

- 以请教为主，不以汇报结论为主。结论都说成”我目前的理解是……“。
- Boţ 是 JOTA 这篇论文的处理编辑，$\alpha = 3$ 临界情形的迭代点收敛也是他近年的工作。涉及 JOTA 的局限时，说”留下的问题”，不说”缺陷”。
- 他熟悉 Lyapunov 分析，第 1、2 节的推导不必逐行讲，讲结构和结论即可。

讲稿怎么用： 每一节都是同一个格式：先是几行中文提示（这一节要达到什么、重点强调什么、可以跳过什么）；然后是逐字稿，每段英文后面跟”译”；公式下面跟”读法”。对着 PDF 讲时，只看英文逐字稿；提示和译文是会前准备用的。

数学表达式的口语读法

下标直接读出来即可，s_k 读 “s k”。

写法	口语读法	中文
$f(x_k) - f^\star$	“the function gap” 或 “f of x k minus f star”	函数值误差
$\mathbb{E}[\cdot]$	“the expected …” / “in expectation”	期望

写法	口语读法	中文
$\mathbb{E}\left[V_{k+1} \mid \mathcal{F}_k\right]$	“the conditional expectation of V k plus one given F k”	条件期望
$O\left(1/k^2\right)$	“big-O of one over k squared”	大 O
$o\left(1/k^2\right)$	“little-o of one over k squared”	小 o
$k^{-1/2}$ 或 $1/\sqrt{k}$	“one over root k”	
$k^{-1/3}$	“k to the minus one third”	
$\log k/\sqrt{k}$	“log k over root k”	
LD^2/T^2	“L D squared over T squared”	偏差项
$\sigma D/\sqrt{T}$	“sigma D over root T”	噪声项
$s_k t_k^2$	“s k t k squared”	加速后的权重
$\sum_k k^2\sigma_k^2 < \infty$	“the sum of k squared sigma k squared is finite”	噪声衰减条件
$s_k = c\,k^{-\delta}$	“step sizes decaying like k to the minus delta”	
$\delta = 3/2$	“delta equals three halves”	
$\alpha_k = 1 - \alpha/k$	“alpha k equals one minus alpha over k”	标准动量
$\alpha \geq 3$ / $\alpha > 3$	“alpha at least three” / “alpha bigger than three”	
$t_{k+1} \leq 2t_k$	“t k plus one is at most twice t k”	
(K_1), $\left(K_1^+\right)$, $\left(K_2^+\right)$	“K one”，“K one plus”，“K two plus”	
ℓ^1，ℓ^2	“l-one”，“l-two”；或“summable”，“square-summable”	可和 / 平方可和
$\nu^2\|\nabla f\|^2$	“nu squared times the squared gradient norm”	相对噪声
$\nu_0(\alpha)$	“nu zero of alpha”	阈值
$\operatorname{dist}(z_k, S)^2$	“the squared distance from z k to the solution set”	
$\inf_k s_k > 0$	“step sizes bounded away from zero”	步长有正下界
a.s.	“almost surely”	几乎必然
$x^\star$, $f^\star$	“x star”，“f star”	

开场（2 分钟）

提示： 说明材料的来源和结构，把讨论引到”噪声模型”这个入口。重点是让他知道你是沿着他给的方向读的，并把结论先说一遍。开场不要拿出具体研究问题，留到第 4 节。

逐字稿：

> Thank you for taking the time today. I sent you a short note before the meeting. I will walk through it briefly, and then I would very much like to hear your thoughts.

译：谢谢您今天抽出时间。会前我发了一份简短的笔记。我先简单讲一遍，然后很想听听您的看法。

> Last time you suggested that I start from the JOTA paper by Attouch, Fadili and Kungurtsev on the stochastic Ravine method. While reading it, I tried to place it in the broader picture of stochastic acceleration for smooth convex problems.

译：上次您建议我从 Attouch、Fadili、Kungurtsev 关于随机 Ravine 方法的 JOTA 论文开始。读的过程中，我试着把它放进光滑凸问题随机加速的整体图景里。

> The note has four parts. First, the SGD baseline: its bias–variance bound and the lower bound. Second, the same analysis for stochastic Nesterov. Third, an overview of related work, organized by noise model. And fourth, where JOTA sits and what seems to remain open.

译：笔记分四部分。第一，SGD 基准：它的偏差–方差界和下界。第二，对随机 Nesterov 做同样的分析。第三，按噪声模型整理的相关工作。第四，JOTA 的位置，以及看起来还开放的问题。

> My main takeaway so far is this: whether stochastic Nesterov accelerates depends mainly on the noise model. I would like to check this understanding with you, and I would be very glad to hear which directions you find most worthwhile.

译：我目前最主要的体会是：随机 Nesterov 能否加速，主要取决于噪声模型。我想和您核对一下这个理解，也很想听听您认为哪些方向最值得做。

第 1 节 SGD 基准（6 分钟）

提示： 这一节要立起两个后面反复用到的东西：**偏差–方差模板**和**下界**。噪声表只点名 (N2)、(N5)、(N6)，这三个标号是全文的坐标系。步长表和 a.s. 注记在时间紧时跳过（下面标了”可跳过”）。下界讲完停一下，看他是否认同。

逐字稿：

> Let me start with the baseline, plain SGD for a convex and L-smooth function. Table 1 lists the noise assumptions used in the literature. I will mainly refer to three of them: N2 is persistent noise with bounded variance, N5 is relative noise, where the variance is bounded by the squared gradient, and N6 is decaying noise.

译：我先从基准讲起，即凸且 L-光滑函数上的普通 SGD。Table 1 列出了文献中用到的噪声假设。我主要会用到其中三个：N2 是方差有界的持续噪声，N5 是相对噪声，即方差被梯度平方控制，N6 是衰减噪声。

> Under unbiasedness and bounded variance, the standard one-step inequality says that the distance to a minimizer decreases by at least s t times the function gap, and the price is the noise term s t squared sigma squared.

译：在无偏和方差有界的假设下，标准的单步不等式说的是：到极小点的距离至少减少 s_t 乘函数值误差，代价是噪声项 $s_t^2\sigma^2$。

$$\mathbb{E}_t \parallel x_{t+1} - x^\star \parallel^2 + s_t\Delta_t \leq \parallel x_t - x^\star \parallel^2 + s_t^2\sigma^2$$

读法：“the expected squared distance at t plus one, plus s t times the gap, is at most the squared distance at t, plus s t squared sigma squared.”

> Summing this up and using Jensen’s inequality gives the bias–variance bound, equation two.

译：把它求和并用 Jensen 不等式，就得到偏差–方差界，也就是式 (2)。

$$\mathbb{E}\left[f(\tilde{x}_k) - f^\star\right] \leq \frac{D^2}{S_k} + \frac{\sigma^2 \sum_{t<k} s_t^2}{S_k}, \qquad S_k = \sum_{t<k} s_t$$

读法：“the expected gap at the averaged point is at most D squared over S k, plus sigma squared times the sum of s t squared, over S k”；S_k 读 “the sum of the step sizes”。

> I would like to keep this shape in mind, because it will appear again: initial error plus accumulated noise, divided by the total weight. A larger step size reduces the bias but increases the variance, and the rate comes from balancing the two.

译：我想先记住这个形状，因为后面还会出现：初始误差加累积噪声，除以总权重。步长大，偏差减小但方差增大，速度来自两者的平衡。

（可跳过）

> With a known horizon T, a constant step of order D over sigma root T gives L D squared over T plus sigma D over root T. Without knowing T, step sizes like one over root t give log k over root k.

译：如果事先知道总步数 T，取常数步长，阶为 $D/(\sigma\sqrt{T})$，得到 $LD^2/T + \sigma D/\sqrt{T}$。不知道 T 时，取 $1/\sqrt{t}$ 这样的步长，得到 $\log k/\sqrt{k}$。

> The key point of this section is the lower bound.

译：这一节的关键是下界。

$$\Omega\left(\frac{LD^2}{T^2} + \frac{\sigma D}{\sqrt{T}}\right)$$

读法：“Omega of L D squared over T squared, plus sigma D over root T.”

> The first term is the deterministic lower bound, and the second one comes from information-theoretic arguments. Lan’s AC-SA attains both. So acceleration can only improve the first term. The second term is already attained by SGD, which means that under persistent noise there is no asymptotic acceleration.

译：第一项是确定性下界，第二项来自信息论论证。Lan 的 AC-SA 两项都达到了。所以加速只能改善第一项。第二项 SGD 已经达到了，这意味着持续噪声下没有渐近加速。

（说完停一下。）

（可跳过）

> For almost-sure convergence, the step sizes need to be square-summable. So with step sizes like t to the minus p, p has to be bigger than one half, and the rate can get arbitrarily close to one over root k, but not reach it. The same thing will happen for Nesterov.

译：要得到几乎必然收敛，步长需要平方可和。所以步长取 t^{-p} 时，p 必须大于 $1/2$，速度可以任意接近 $1/\sqrt{k}$，但达不到。Nesterov 也会出现同样的情况。

第 2 节 随机 Nesterov：同结构、同极限（10 分钟）

提示： 这是核心论证：**动量把分母从 k 放大到 k^2，但同时把每一步的噪声放大 t_k^2 倍；持续噪声下两者抵消，最终还是 $1/\sqrt{k}$。** t_k 和 (K) 条件是 JOTA 的语言，他很熟悉，讲快一点。两种噪声制度的对比必须讲清楚。接近 2 小时时，可以在白板上推一遍 $\delta = 3/2$ 的平衡。

逐字稿：

> Now the same analysis for stochastic Nesterov. The iteration is: y k equals x k plus alpha k times the difference x k minus x k minus one, and x k plus one equals y k minus s k times the stochastic gradient at y k.

译：现在对随机 Nesterov 做同样的分析。迭代是：y_k 等于 x_k 加上 α_k 乘以 x_k 与 x_{k-1} 之差，然后 x_{k+1} 等于 y_k 减去 s_k 乘以 y_k 处的随机梯度。

$$y_k = x_k + \alpha_k\,(x_k - x_{k-1}), \qquad x_{k+1} = y_k - s_k\left(\nabla f\left(y_k\right) + e_k\right)$$

> Following JOTA, the momentum is encoded by the sequence t k, with alpha k equal to t k minus one, over t k plus one. For the standard choice, alpha k equals one minus alpha over k, t k grows like k over alpha minus one. The condition K one corresponds to alpha at least three, and K one plus to alpha bigger than three. K two is the l-two condition on s k t k sigma k, and K two plus is the l-one condition.

译：按照 JOTA，动量用序列 t_k 来编码，$\alpha_k = (t_k - 1)/t_{k+1}$。对标准选择 $\alpha_k = 1 - \alpha/k$，t_k 大约是 $k/(\alpha - 1)$。条件 (K_1) 对应 $\alpha \geq 3$，$\left(K_1^+\right)$ 对应 $\alpha > 3$。(K_2) 是 $s_k t_k \sigma_k$ 的 ℓ^2 条件，$\left(K_2^+\right)$ 是 ℓ^1 条件。

> The energy is V k equals s k t k squared times the function gap, plus one half the squared distance from z k to the solution set. Under K one, one step gives the following.

译：能量是 V_k 等于 $s_k t_k^2$ 乘函数值误差，再加 z_k 到解集距离平方的一半。在 (K_1) 下，一步得到下面的不等式。

$$V_k = s_k t_k^2\,(f(x_k) - f^\star) + \tfrac{1}{2}\,\mathrm{dist}\,(z_k, S)^2$$

$$\mathbb{E}\left[V_{k+1} \mid \mathcal{F}_k\right] \le V_k + 4s_k^2 t_k^2 \sigma_k^2$$

读法：“the conditional expectation of V k plus one is at most V k, plus four s k squared t k squared sigma k squared.”

> So the noise enters only through this one term. Compared with SGD, where the term was s t squared sigma squared, there is an extra factor t k squared. This is exactly what I mean by momentum amplifying the noise.

译：所以噪声只通过这一项进入。和 SGD 的 $s_t^2\sigma^2$ 相比，多了一个因子 t_k^2。这就是我说”动量放大噪声”的准确含义。

> Summing up and taking expectations, we get the following bound.

译：求和并取期望，得到下面的界。

$$\mathbb{E}\left[f(x_k) - f^\star\right] \le \frac{\mathbb{E}[V_1]}{s_k t_k^2} + \frac{4\sum_{i\le k} s_i^2 t_i^2\, \mathbb{E}\left[\sigma_i^2\right]}{s_k t_k^2}$$

读法：“the expected gap is at most E V one over s k t k squared, plus four times the sum of s i squared t i squared sigma i squared, over s k t k squared.”

> This is the same bias–variance template as for SGD, with s k t k squared in place of the sum of the step sizes. Acceleration enlarges the denominator from order k to order k squared, but it also multiplies each noise contribution by t i squared.

译：这和 SGD 的偏差–方差模板完全一样，只是用 $s_k t_k^2$ 代替了步长之和。加速把分母从 k 阶放大到 k^2 阶，但也把每一项噪声贡献乘上了 t_i^2。

> Now take t k of order k and look at the two regimes. If the noise decays so that the sum of k squared sigma k squared is finite, then with a constant step both terms are of order one over k squared, and acceleration is preserved. With K one plus, we even get almost surely little-o of one over k squared.

译：现在取 t_k 为 k 阶，看两种情形。如果噪声衰减得使 $\sum_k k^2\sigma_k^2$ 有限，那么取常数步长时两项都是 $1/k^2$ 阶，加速得以保留。在 $\left(K_1^+\right)$ 下，甚至几乎必然得到 $o\left(1/k^2\right)$。

> If the noise is persistent, sigma k equal to sigma, we need decaying steps, s k equal to c times k to the minus delta. Then the bias is of order k to the delta minus two, and the variance is of order k to the one minus delta. They balance at delta equals three halves, which gives log k over root k in expectation.

译：如果噪声持续，$\sigma_k \equiv \sigma$，就需要衰减步长 $s_k = c\,k^{-\delta}$。这时偏差是 $k^{\delta-2}$ 阶，方差是 $k^{1-\delta}$ 阶。两者在 $\delta = 3/2$ 时平衡，期望意义下得到 $\log k/\sqrt{k}$。

噪声	步长	偏差	方差	结论
(N6) 衰减，$\sum_k k^2\sigma_k^2 < \infty$	常数	$1/k^2$	$1/k^2$	加速保留

噪声	步长	偏差	方差	结论
(N2) 持续，$\sigma_k \equiv \sigma$	$s_k = c\,k^{-\delta}$	$k^{\delta-2}$	$k^{1-\delta}$	$\delta = 3/2$ 时平衡，得 $\log k/\sqrt{k}$

备用（他问平衡怎么来时）：

> The numerator of the variance term is the sum of i to the two minus two delta, which is of order k to the three minus two delta. Dividing by k to the two minus delta gives k to the one minus delta. Setting delta minus two equal to one minus delta gives delta equals three halves.

译：方差项的分子是 $\sum_i i^{2-2\delta}$，是 $k^{3-2\delta}$ 阶。除以 $k^{2-\delta}$ 得到 $k^{1-\delta}$。令 $\delta-2=1-\delta$，得 $\delta=3/2$。

> For the almost-sure analysis, we need the sum of k to the two minus two delta to be finite, so delta has to be bigger than three halves, and the rate can only approach one over root k. So under persistent noise, stochastic Nesterov and SGD end at the same order, consistent with the lower bound. Acceleration survives only when the noise decays fast enough.

译：做几乎必然分析时，需要 $\sum_k k^{2-2\delta}$ 有限，所以 δ 必须大于 $3/2$，速度只能接近 $1/\sqrt{k}$。所以在持续噪声下，随机 Nesterov 和 SGD 最终是同一个阶，与下界一致。只有噪声衰减得足够快时，加速才能保留。

第 3 节 相关工作（10 分钟）

提示： 按噪声模型讲三条线，每条线讲”代表结果 + 还缺什么”。对着 PDF 的 Table 2 讲，不必逐格念。讲完三条线，主线就完整了。

逐字稿：

> Results on stochastic acceleration are only comparable under the same noise model and the same convergence notion. So I organized the literature by noise model. Table 2 has three rows.

译：随机加速的结果，只有在同一噪声模型、同一收敛概念下才能比较。所以我按噪声模型整理了文献，Table 2 有三行。

线 1：持续噪声 (N2)——不能加速

- **期望意义**：Lan 2012 的 AC-SA 同时达到 $LD^2/T^2 + \sigma D/\sqrt{T}$，与下界吻合；但要事先知道总迭代数 T。
- **a.s. 意义**：Sebbouh–Gower–Defazio 2021 对随机重球法（SHB）得到接近 $k^{-1/2}$ 的速度；Liu–Yuan 2022 对常数动量的 SHB 和 SNAG 得到 $O\left(k^{-1/3+\varepsilon}\right)$，并声称迭代点收敛。
- **JOTA Remark 3.2**：一般 α_k 下，最好也是期望 $\log k/\sqrt{k}$。

> Under persistent noise, the lower bound already settles the rate: acceleration can only improve the bias term, and Lan’s AC-SA attains both terms. On the almost-sure side, Sebbouh, Gower and Defazio get rates close to one over root k for stochastic heavy ball, and Liu and Yuan get k to the minus one third for constant momentum.

译：持续噪声下，下界已经决定了速度：加速只能改善偏差项，Lan 的 AC-SA 两项都达到了。几乎必然意义下，Sebbouh、Gower、Defazio 对随机重球法得到接近 $1/\sqrt{k}$ 的速度，Liu 和 Yuan 对常数动量得到 $k^{-1/3}$。

被问到再说：JOTA 指出，Liu–Yuan 和 Sebbouh 等的迭代点收敛论证有量词顺序问题：收敛事件依赖于 $x^\star$，需要用可分性做稠密性论证。结论本身成立。

线 2：相对噪声 (N5)——期望意义下能加速

- **模型**：噪声方差不超过 $\nu^2 \| \nabla f\left(y_k\right) \|^2$，噪声随梯度一起变小。strong growth 条件（Schmidt–Le Roux 2013）是典型例子：$\mathbb{E}_\xi \| \nabla f(x;\xi) \|^2 \le \rho \| \nabla f(x) \|^2$，由无偏性即得 (N5)，$\nu^2 = \rho - 1$。它蕴含插值（所有样本在同一个极小点处梯度为 0），但它是噪声条件，和 PL 这类几何条件无关。
- **正面结果**：Vaswani–Bach–Schmidt 2019 在 strong growth 下得到加速 SGD 的期望 $O\left(1/k^2\right)$。Gupta–Siegel–Wojtowytsch 2024（NeurIPS）在 $\mathbb{E} \| g - \nabla f \|^2 \le \sigma^2 \| \nabla f \|^2$ 下给出两个结果，见下方。这里的 σ 就是本文 (N5) 的 ν；JOTA 转述中的“比例常数”指的是它，不是动量 α。
- **负面结果**：Kidambi 等 2018 表明标准动量在随机设定下可能不优于 SGD；Liu–Belkin 2020 针对插值给出了修正格式。
- **还缺**：a.s. 速度、迭代点收敛、对 α 的依赖。

Gupta–Siegel–Wojtowytsch 2024 的具体条件（符号注意：他们把动量记作 ρ_n，他们的 α 是 AGNES 的额外步长，不是 JOTA 的 α_k）

- **标准 NAG（Theorem 1）**：$x_{n+1} = x'_n - \eta g'_n$，$x'_{n+1} = x_{n+1} + \rho_n\left(x_{n+1} - x_n\right)$，$\rho_n = \frac{n}{n+3}$。若 $\sigma < 1$ 且 $0 < \eta \le \frac{1-\sigma^2}{L(1+\sigma^2)}$，则 $\mathbb{E}\left[f(x_n) - f^\star\right] \le \frac{2\mathbb{E}\| x_0 - x^\star \|^2}{\eta n^2}$。$\rho_n \approx 1 - 3/n$，即临界 $\alpha = 3$；$\sigma \to 1$ 时 $\eta \to 0$，常数爆掉，$\sigma \ge 1$ 时没有结论。
- **AGNES（Theorem 3）**：$x'_n = x_n + \alpha v_n$，$x_{n+1} = x'_n - \eta g'_n$，$v_{n+1} = \rho_n(v_n - g'_n)$；$\alpha = \eta$ 时退化为 NAG。取 $0 < \eta < \frac{1}{L(1+\sigma^2)}$，$\alpha = \frac{\eta}{1+\sigma^2}$，$\rho_n = \frac{n}{n+1+a_0}$，$a_0 \ge \frac{2(1-\eta L)}{1-\eta L(1+\sigma^2)}$，则 $\mathbb{E}\left[f(x_n) - f^\star\right] \le \frac{a_0^2 \mathbb{E}\| x_0 - x^\star \|^2}{2\alpha n^2}$，对任意 σ 成立。$a_0 \ge 2$ 对应 $\alpha_{\mathrm{JOTA}} = 1 + a_0 \ge 3$。
- **机制**（inference）：梯度步用 η，动量步只用更小的 $\eta/\left(1+\sigma^2\right)$，噪声不被动量放大；代价是常数约按 $L\left(1+\sigma^2\right)^2$ 增长。
- **还缺什么**：两者都只是期望意义下的 $O\left(1/n^2\right)$；标准 NAG 在 $\alpha > 3$ 时是否加速没有找到明确结果；a.s. $o\left(1/k^2\right)$ 和迭代点收敛都没有找到结果（to be verified）。
- **JOTA 没有分析相对噪声**：它的（K_2）把 $\sum_k s_k^2 t_k^2 \sigma_k^2 < \infty$ 当作前提。相对噪声下这等于先假设 $\sum_k s_k^2 t_k^2 \| \nabla f\left(y_k\right) \|^2 < \infty$，而这正是要证的结论之一（Thm 3.3），是循环的。

> Relative noise means that the noise shrinks with the gradient, as in interpolation. Here acceleration is real: Vaswani and coauthors, and later Gupta, Siegel and Wojtowytsch, prove big-O of one over k squared in expectation, under a condition on the noise ratio. But I have not found almost-sure rates or iterate convergence in this setting.

译：相对噪声的意思是噪声随梯度一起变小，比如插值情形。这里加速是真实的：Vaswani 等人，以及后来的 Gupta、Siegel、Wojtowytsch，在噪声比例满足条件时证明了期望意义下的 $O\left(1/k^2\right)$。但在这个设定下，我还没找到几乎必然意义的速度或迭代点收敛。

线 3：衰减噪声 (N6)——衰减够快时能加速

- **代表工作**：JOTA（下一节详讲）；Salzo 2025 把临界情形的迭代点收敛推广到不精确和随机梯度（to be verified）。
- **代价**：噪声衰减靠增大 batch，按样本数计不占优（见追问 5）。

> With decaying noise, acceleration survives if the variance decays fast enough, roughly if the sum of k squared sigma k squared is finite. The JOTA paper covers this case for general momentum, and I will come back to it in the next part.

译：衰减噪声下，只要方差衰减得够快，大致是 $\sum_k k^2\sigma_k^2$ 有限，加速就能保留。JOTA 对一般动量覆盖了这种情形，下一部分我再细讲。

可选：连续时间的线（时间充裕时提一句）

Maulén-Soto、Fadili、Attouch、Ochs 2025 研究随机惯性 SDE，用时间尺度变换和平均把一阶随机结论转到二阶系统。这是 Boţ 熟悉的路线。

> There is also a continuous-time line, the stochastic inertial dynamics studied by Maulén-Soto, Fadili, Attouch and Ochs. I wonder whether it would help to start there before the discrete schemes.

译：还有一条连续时间的线，就是 Maulén-Soto、Fadili、Attouch 和 Ochs 研究的随机惯性动力系统。我在想，在做离散格式之前先从那里入手会不会有帮助。

收尾——全场的高潮，语速放慢

> Putting the three lines together: persistent noise is settled by the lower bound, decaying noise is largely covered by JOTA, and relative noise is where acceleration is real but only finite-time results in expectation are known. That seems a natural place for asymptotic almost-sure analysis, though I may well have missed some work.

译：把三条线放在一起：持续噪声已经被下界决定了，衰减噪声基本被 JOTA 覆盖，相对噪声是加速真实存在、但只有有限时间期望结果的地方。这看起来很适合做渐近的几乎必然分析，不过我很可能漏看了一些工作。

“I may well have missed some work” 一定要说。相对噪声下是否已有 a.s. 结果，你的笔记里标的是 to be verified。

第 4 节 JOTA 与剩余问题（12 分钟）

提示： 先讲 JOTA 做了什么（5 分钟），再挑 Table 3 的两格（2 分钟），最后拿出三个问题（5 分钟）。语气保持正面：说”留下的问题”，不说”缺陷”。

1. JOTA 做了什么

结果	内容	口语怎么说
Thm 2.1	Nesterov 的 y_k 序列恰好走 Ravine 格式，$\gamma_k = \alpha_{k+1}$；结果可以互相转移	“gamma k equals alpha k plus one”
Thm 3.1(i)	$(K_1)+(K_2) \Rightarrow$ a.s. $f(x_k)-f^\star = O\left(1/\left(s_k t_k^2\right)\right)$，并有期望界	“big-O of one over s k t k squared, almost surely”

结果	内容	口语怎么说
Thm 3.1(ii)	$\left(K_1^+\right) \Rightarrow$ $\sum_k s_k t_{k+1}\left(f\left(x_k\right)-f^\star\right)<\infty$，$\sum_k t_k\|x_k-x_{k-1}\|^2<\infty$；再加 $\sum_k t_{k+1}/t_k^2=\infty \Rightarrow o$ 速度	“the weighted gaps are summable, which gives little-o”
Thm 3.1(iii)	$\alpha_k \in [0,1]$、$\inf_k s_k>0$、$\left(K_1^+\right)$、$\left(K_2^+\right)$ ⇒ 迭代点 a.s. 弱收敛到极小点集上的随机变量	“the iterates converge weakly almost surely to a random minimizer”
Thm 3.3	常数步长下 $\sum_k t_{k+1}^2\|\nabla f\left(y_k\right)\|^2<\infty$，对应高分辨率 ODE 里的 Hessian 驱动阻尼（附录 B）	“t k squared times the squared gradient is summable”
Cor 4.1	$\alpha_k=1-\alpha/k$，$\alpha>3$，$\left(k s_k \sigma_k\right) \in \ell^1 \Rightarrow o\left(1/\left(s_k k^2\right)\right)$、$\sum_k k^2\|\nabla f\left(y_k\right)\|^2<\infty$、迭代点收敛	“for alpha bigger than three, little-o of one over k squared”
Cor 4.2 / 4.3	$\alpha_k=1-\alpha/k^r$：速度变慢为 $o\left(1/\left(s_k k^{2r}\right)\right)$，噪声条件变弱；常数 α_k：只有可和性	“a trade-off between speed and robustness to noise”

> As I understand it, JOTA has three main points. First, the Nesterov and Ravine sequences are linked by gamma k equals alpha k plus one, so results transfer between them. Second, with the energy s k t k squared times the function gap, plus half the squared distance from z k to the solution set, they get almost-sure big-O and little-o rates for general momentum, under summable noise. Third, with a constant step size, they get summability of t k squared times the squared gradient, which reflects Hessian-driven damping.

译：按我的理解，JOTA 有三个要点。第一，Nesterov 序列和 Ravine 序列通过 $\gamma_k=\alpha_{k+1}$ 联系起来，结果可以互相转移。第二，用能量 $s_k t_k^2$ 乘函数值误差、再加 z_k 到解集距离平方的一半，在噪声可和的条件下，对一般动量得到几乎必然的 O 和 o 速度。第三，常数步长下得到 t_k^2 乘梯度平方的可和性，对应 Hessian 驱动的阻尼。

如果他问技术细节，可以补充：迭代点收敛用了 Opial 引理，并用可分性做稠密性论证，来处理收敛事件依赖 $x^\star$ 的问题。你关心的是有限维，这一点在有限维下更简单。

2. Table 3：只挑两格讲

> For the standard choice alpha k equals one minus alpha over k, Table 3 lists what is known and what is open. With alpha bigger than three and decaying noise, JOTA covers almost everything; what remains is whether the l-one condition K two plus is really needed. With relative noise, the whole row is still open.

译：对标准选择 $\alpha_k=1-\alpha/k$，Table 3 列出了已知和未知。$\alpha>3$ 且噪声衰减时，JOTA 几乎都覆盖了，剩下的是 ℓ^1 条件 $\left(K_2^+\right)$ 是否真的必要。相对噪声这一行则完全是开放的。

3. 三个问题——第一个多讲

问题 1（首选）：相对噪声下的阈值

> Under relative noise with alpha k equal to one minus alpha over k, is there a threshold nu zero of alpha on the noise ratio, such that below it we get almost-sure little-o of one over k squared and iterate convergence?

译：在相对噪声和 $\alpha_k = 1 - \alpha/k$ 下，噪声比例是否存在一个阈值 $\nu_0(\alpha)$，低于它时能得到几乎必然的 $o\left(1/k^2\right)$ 和迭代点收敛?

已知情况（口头补充）：

> In expectation, Gupta, Siegel and Wojtowytsch show acceleration for Nesterov’s method at alpha equals three when sigma is below one, and their AGNES scheme accelerates for any sigma. But JOTA’s summability condition cannot be applied directly here, because under relative noise it already requires the weighted gradients to be summable, which is part of what we want to prove.

译：在期望意义下，Gupta、Siegel、Wojtowytsch 证明了 Nesterov 方法在 $\alpha = 3$、$\sigma < 1$ 时加速，他们的 AGNES 对任意 σ 都加速。但 JOTA 的可和条件不能直接用在这里：相对噪声下它本身就要求加权梯度可和，而这正是我们要证的一部分。

如果时间多，可以补一句直觉：相对噪声下单步不等式里的噪声项变成 $s_k^2 t_{k+1}^2 \nu^2 \| \nabla f\left(y_k\right) \|^2$，不再是外加的可和项，而是要被能量里的梯度项吸收。能否吸收取决于 ν 和 α，这就是阈值的来源。（inference，尚未推导）

> My intuition is that the noise term becomes proportional to the squared gradient, so it has to be absorbed by the energy rather than summed. Whether that works should depend on nu and alpha.

译：我的直觉是，噪声项变成和梯度平方成比例，所以它要被能量吸收，而不是靠求和控制。能不能做到应该取决于 ν 和 α。

问题 2：持续噪声下 SNAG/SRAG 的迭代点收敛

> Under persistent noise, the rate requires step sizes going to zero, but the existing iterate-convergence result requires the step sizes to stay bounded away from zero. Can iterate convergence still be shown?

译：持续噪声下，要得到速度需要步长趋于 0，但已有的迭代点收敛结果要求步长有正的下界。还能证明迭代点收敛吗?

问题 3：临界 $\alpha = 3$、衰减噪声

> At the critical value alpha equals three with decaying noise, is an almost-sure little-o rate possible? I am not sure whether this is already known.

译：在临界值 $\alpha = 3$、噪声衰减的情形下，能得到几乎必然的 o 速度吗？我不确定这是否已经有结果。

这个问题和他自己的工作直接相关，提完就停，让他来说。

4. 发出前请核对一处原文

你的终版第 4 节写了两处 “nondecreasing”：“permits nondecreasing step sizes” 和 “the nondecreasing-step condition”。JOTA Theorem 3.1 假设的是 s_k **非增**（nonincreasing），迭代点收敛 (iii) 还要求 $\inf_k s_k > 0$。所以问题 2 里真正的冲突是：持续噪声要求 $s_k \to 0$，而迭代点收敛要求 $\inf_k s_k > 0$。如果 PDF 已经发出，讲到这里时口头更正：

> A small correction to the note: JOTA assumes nonincreasing step sizes, not nondecreasing.

译：对笔记做个小更正：JOTA 假设的是步长单调不增，不是单调不减。

讨论环节：想从 Boţ 那里得到的答案

提示： 目标是带回四个答案：噪声模型、收敛度量、能否加几何假设、先做连续还是离散。不必一次问完，跟着他的话题逐个引出。开放式提问，不设选项。他如果提出另一个方向（比如他之前说的另外两个 idea），先跟着记，不当场辩护相对噪声方向。

逐字稿：

过渡句（讲完第 4 节后）：

> That is all I prepared. I would be very glad to hear your view, both on whether this picture is right, and on which direction you think is worth pursuing.

译：我准备的就是这些。很想听听您的看法：这个图景是否正确，以及您认为哪个方向值得做。

四个问题（按需要抽用）：

> When you think about acceleration in the stochastic setting, which noise model do you have in mind?

译：您考虑随机设定下的加速时，心里想的是哪种噪声模型？

> Would you consider almost-sure rates and iterate convergence as the main target, or also rates in expectation?

译：您是把几乎必然的速度和迭代点收敛当作主要目标，还是也关心期望意义下的速度？

> Would it be reasonable to add a geometric assumption, such as a growth condition, or should we stay with general convex functions?

译：加一个几何假设（比如增长条件）是否合理？还是应该停留在一般凸函数？

> Would you start from the continuous-time dynamics, or work directly with the discrete schemes?

译：您会先从连续时间动力系统入手，还是直接做离散格式？

结束语：

> Thank you, this helps a lot. I will read the references you mentioned and come back with a more concrete plan.

译：谢谢您，这很有帮助。我会去读您提到的文献，然后带着更具体的计划再来找您。

会后：把他的回答记到项目笔记里。

可能被追问的问题

提示： 下面七个问题最可能被问到，每个都给了英文回答和译文。标 to be verified 的地方，回答时要明确说“I am not sure yet”。

1. “持续噪声下虽然不能加速，迭代点收敛不也值得做吗？”

> I agree. The rate exponent is fixed by the lower bound, but little-o rates and iterate convergence are asymptotic questions that are still open there. That is my second question.

译：同意。速度指数被下界定死了，但 o 速度和迭代点收敛是渐近问题，在那里仍然是开放的。这就是我的第二个问题。

2. “为什么要 a.s.，期望结果不够吗？”

> A bound in expectation describes the average behavior. It does not give little-o of one over k squared along a single trajectory, or convergence of the iterates. For those, we need almost-sure tools such as the Robbins–Siegmund lemma.

译：期望意义的界描述的是平均行为，它推不出单条轨迹上的 $o\left(1/k^2\right)$，也推不出迭代点收敛。要得到这些，需要 Robbins–Siegmund 引理这类几乎必然的工具。

3. “相对噪声下已知结果具体需要什么条件？”

> Under the strong growth condition, the expected squared stochastic gradient is at most rho times the squared gradient. With unbiasedness this gives N5 with nu squared equal to rho minus one. The known results need either a small enough noise ratio or modified parameters. I am not sure yet about the exact thresholds in each paper.

译：在 strong growth 条件下，$\mathbb{E}\,\|\,g_k\,\|^2 \le \rho\,\|\,\nabla f\,\|^2$。加上无偏性，就得到 (N5)，其中 $\nu^2=\rho-1$。已知结果要么需要噪声比例足够小，要么需要修改参数。各篇论文的具体阈值我还不确定。

补充（他追问时）：SGC 是噪声条件，不是 PL 那样的几何条件。SGC 蕴含插值；反过来，插值一般只能推出更弱的 weak growth 条件 $\mathbb{E}\,\|\,\nabla f(\,x;\xi\,)\,\|^2 \le 2\rho L\,(\,f(\,x\,)-f^{\star}\,)$（Vaswani 等 2019）。

4. “$\alpha=3$ 的临界情形你怎么看？”

> As far as I understand, iterate convergence at alpha equals three in the deterministic case was settled in your recent work with Fadili and Nguyen, and Salzo may have extended it to

> stochastic gradients. I am not sure what remains in the stochastic case, and I would be glad to hear your view.

译：据我理解，确定性情形下 $\alpha = 3$ 的迭代点收敛已经在您和 Fadili、Nguyen 最近的工作中解决，Salzo 可能已经推广到随机梯度。我不确定随机情形还剩下什么，很想听听您的看法。（Salzo 的结果 to be verified。）

5. “衰减噪声靠增大 batch 实现，这还算加速吗？”

> In terms of iterations, yes. In terms of samples, no. In JOTA’s example, the batch size grows like k to the four plus delta, so the total number of samples N grows like k to the five plus delta. In terms of N, the rate is N to the minus two over five plus delta, which is slower than the one over root N of SGD.

译：按迭代次数算是加速，按样本数算不是。在 JOTA 的例子里，batch 大小按 $k^{4+\delta}$ 增长，所以总样本数 N 按 $k^{5+\delta}$ 增长。按 N 算，速度是 $N^{-2/(5+\delta)}$，比 SGD 的 $1/\sqrt{N}$ 更慢。

6. “为什么不考虑强凸？”

> In the strongly convex case, linear convergence to a noise-dominated region is already well studied. I am more interested in the asymptotic behavior for general convex smooth functions. But if you think a geometric assumption would help, I would be happy to consider it.

译：强凸情形下，线性收敛到噪声主导区域已经研究得很多。我更关心一般凸光滑函数上的渐近行为。不过如果您觉得几何假设有帮助，我很愿意考虑。

7. “你对 JOTA 的证明有什么看法？”（只在他主动问到证明细节时才说）

> While reproducing the proofs, I noticed two small points, and I would like to check whether my fixes are right. In equation sixteen, the sign of the noise term does not match equations fifteen and seventeen. And in Theorem 3.1, part three, the random variable eta is taken out of a conditional expectation, although it is not F k measurable. Both seem fixable without changing the results.

译：复现证明时我注意到两个小地方，想核对一下我的修改是否正确。式 (16) 中噪声项的符号与式 (15)、(17) 不一致。Theorem 3.1(iii) 把随机变量 η 提到了条件期望外面，但 η 不是 $\mathcal{F}_k$-可测的。两处看起来都可以修复，结论不变。